

Fiche de révision : métriques et déséquilibre

Predicting User Sentiment in Software Issue Reports · Yann MASSOUAM, Vénus BAKIKO, Faïçal DIELO

1. La matrice de confusion (notre meilleur modèle : TF-IDF + Naive Bayes)

On compare ce que le modèle **prédit** avec la **vérité**, sur les 1 185 avis de test.

	il dit néгатif	il dit neutre	il dit positif	total réel
vrais négatifs	291	0	81	372
vrais neutres	22	0	31	53
vrais positifs	57	0	703	760
total prédit	370	0	815	1 185

La diagonale (291, 0, 703) = les bonnes réponses. **Les négatifs et positifs sont bien prédits.** La colonne **neutre est à 0** : le modèle ne prédit *jamais* la classe neutre.

2. Les métriques, expliquées simplement

Image : on pêche les poissons rouges dans un étang (les rouges = une classe, par ex. les positifs).

- **Accuracy (exactitude)** : sur *tous* les avis, le % de bonnes réponses. $\frac{291 + 0 + 703}{1185} = \mathbf{0,84}$. *Piège* : 64 % des avis sont positifs, donc dire « positif » tout le temps donne déjà ~64 % sans rien comprendre.
- **Précision** d'une classe : *parmi ce que tu as remonté dans le filet, combien est vraiment de cette classe ?* (qualité des prises). Positifs : $703/815 = \mathbf{0,86}$.
- **Rappel** d'une classe : *parmi tout ce qu'il fallait attraper, combien tu en as attrapé ?* (couverture). Positifs : $703/760 = \mathbf{0,93}$. Neutres : $0/53 = \mathbf{0}$ (aucun retrouvé).
- **F1** : combine précision et rappel en un seul chiffre. *Si l'un des deux est nul, le F1 est nul.*
- **Macro-F1** : moyenne des F1 des 3 classes à **égalité** (peu importe leur taille).

Classe	Précision	Rappel	F1
négatif	0,79	0,78	0,78
neutre	0	0	0,00
positif	0,86	0,93	0,89

$$\text{Macro-F1} = \frac{0,78 + 0,00 + 0,89}{3} = \mathbf{0,56}$$

La leçon centrale

Accuracy 0,84 (a l'air super) **mais Macro-F1 0,56** (dit la vérité). L'accuracy compte chaque *avis* à égalité, donc la grosse classe l'écrase. Le macro-F1 compte chaque *classe* à égalité, donc il voit qu'on ignore le neutre. $\Rightarrow$ Sur un jeu déséquilibré, on regarde le **macro-F1** et le **rappel par classe**, pas l'accuracy.

3. Le constat des zéros : qu'avons-nous fait ?

Le constat. La classe neutre (seulement 4,5 % des données) n'est jamais prédite. **Pourquoi c'est normal** (et pas un bug) :

- **Déséquilibre extrême** : le neutre est minuscule.
- **Label « proxy »** : un avis 3 étoiles ressemble souvent à un négatif ou un positif (« ça marche mais bof »).
- **Mécanique de Naive Bayes** : prédiction = *probabilité a priori de la classe* $\times$ *vraisemblance des mots*. Le neutre a un a priori minuscule et des mots peu distinctifs, donc sa probabilité n'est *jamais la plus grande* : il n'est jamais choisi.

Notre démarche (3 étapes, à raconter au jury) :

1. **Détecter** : c'est le macro-F1 et le rappel par classe (pas l'accuracy) qui ont révélé le problème.
2. **Vérifier que ce n'est pas une erreur** (voir la checklist en §5).
3. **Corriger** le déséquilibre par rééchantillonnage, appliqué **seulement sur l'entraînement** :

Stratégie	Accuracy	Macro-F1	Rappel neutre
aucune (référence)	0,84	0,56	0,00
SMOTE (crée des neutres synthétiques)	0,73	0,55	0,19
sous-échantillonnage	0,60	0,51	0,47

4. Conclusions à en tirer

- Une **accuracy élevée** peut cacher une classe entière ignorée : il faut toujours regarder par classe.
- Le **rééchantillonnage fait exister la classe rare** (rappel neutre $0 \rightarrow 0,19 \rightarrow 0,47$), **au prix d'un peu d'accuracy** : on ne crée pas de la performance gratuite, on *redistribue* les erreurs.
- Le choix de la métrique est une **décision** : on a réglé les modèles sur le macro-F1, justement pour ne pas récompenser un modèle qui ignore le neutre.

5. Comment vérifier qu'on ne s'est pas trompé (checklist anti-bug)

À dégainer si le jury doute des zéros

- **Les lignes somment aux effectifs réels** : $291 + 0 + 81 = 372$ négatifs, $22 + 0 + 31 = 53$ neutres, $57 + 0 + 703 = 760$ positifs. La matrice est cohérente.
- **Le neutre est bien présent à l'entraînement** (~ 212 exemples) : le modèle le voit, mais ne le choisit jamais. Ce n'est donc pas une classe oubliée.
- **Résultat reproductible** : graine fixe (RANDOM_STATE = 42), mêmes chiffres à chaque exécution.
- **Spécifique au modèle** : d'autres réglages, et surtout les pipelines avec rééchantillonnage, *prédisent* le neutre. Le zéro n'est pas systématique.
- **Cohérence inter-expériences** : la baseline du test de déséquilibre et le point « 100 % des composantes » de la PCA donnent exactement le même score (0,56), preuve que les briques sont cohérentes.

6. Les points subtils qui prouvent la maîtrise

- Nommer le phénomène : c'est l'« **accuracy paradox** » / effondrement de la classe minoritaire, attendu en cas de fort déséquilibre.
- Rappeler que le **label vient des étoiles** (signal approximatif) : limite assumée, pas cachée, surtout pour le 3 étoiles ambigu.
- Insister sur l'**anti-fuite** : déduplication des textes et rééchantillonnage uniquement sur le train, pour une évaluation honnête.
- Conclure par le compromis : « **quelle métrique selon l'objectif** » : si l'on veut surtout remonter les avis neutres, on choisit le sous-échantillonnage (rappel neutre 0,47) ; sinon SMOTE est le meilleur équilibre.

En une phrase : « Accuracy 0,84 mais macro-F1 0,56, car le neutre n'est jamais prédit ; on l'a détecté avec le rappel par classe, vérifié que ce n'est pas un bug, et corrigé avec SMOTE. »