

Script de présentation orale

Predicting User Sentiment in Software Issue Reports

Yann MASSOUAM · Vénus BAKIKO · Faïçal DIELO

ST2MLE : Machine Learning for IT Engineers

Mode d'emploi. Ce document répartit le pitch entre les trois présentateurs, slide par slide. Chaque bloc coloré indique qui parle et le texte à dire. Durée visée : environ 18 à 20 minutes, soit à peu près une minute par slide. Les mêmes textes sont disponibles dans les notes du présentateur du fichier PowerPoint.

Présentateur	Slides	Partie
Yann MASSOUAM	1 à 6	Introduction, données et début de la chaîne
Vénus BAKIKO	7 à 12	Vectorisation, modèles, métriques et résultats
Faïçal DIELO	13 à 18	Réglages, conclusion et perspectives

Partie 1 : Yann MASSOUAM (slides 1 à 6)

Slide 1 : Page de titre

Bonjour à tous. Nous sommes Yann, Vénus et Faïçal, et nous vous présentons notre projet de Machine Learning : prédire le sentiment d'avis d'utilisateurs sur des applications, en trois classes, négatif, neutre et positif. En une vingtaine de minutes, nous allons montrer comment, à partir d'un simple texte d'avis, on construit une chaîne complète qui nettoie, transforme, entraîne et évalue plusieurs modèles, puis nous expliquerons pourquoi certains choix comptent vraiment.

Slide 2 : Plan

Voici notre fil conducteur. On part du problème, puis des données, puis on déroule la chaîne de traitement de gauche à droite. On insiste sur deux idées fortes : la vectorisation, c'est à dire le passage du texte aux nombres, et les métriques, parce que sur ce projet une bonne exactitude peut cacher un modèle qui ne fonctionne pas. On termine par les réglages classiques et la conclusion.

Slide 3 : Le problème

Le but est concret : à partir du texte d'un avis, prédire automatiquement s'il est négatif, neutre ou positif. C'est de l'apprentissage supervisé, car chaque avis d'entraînement possède déjà une étiquette. L'intérêt pratique est réel : sur une application qui reçoit des milliers d'avis, on veut repérer vite les mécontents, suivre la satisfaction, et éviter de tout lire à la main.

Slide 4 : Les données

Point important : nous n'utilisons pas de données inventées, mais de vrais avis Facebook téléchargés sur Kaggle. Chaque avis a une note de une à cinq étoiles que l'on transforme en sentiment : une ou deux étoiles, c'est négatif, trois, c'est neutre, quatre ou cinq, c'est positif.

On supprime les doublons de texte pour éviter qu'un même avis se retrouve à la fois en entraînement et en test. Il reste 5 923 avis. Regardez le déséquilibre : deux tiers d'avis positifs et seulement 4,5 pour cent de neutres. Ce déséquilibre sera au cœur de notre analyse.

Slide 5 : La chaîne de traitement

Voici la chaîne complète, à lire de gauche à droite. On part du texte brut, on le nettoie, on le transforme en nombres, on peut rééquilibrer les classes et réduire la dimension, puis on entraîne un modèle réglé, et enfin on évalue. Deux choix d'ingénierie : on nettoie une seule fois car cette étape n'apprend rien, ce qui rend tout plus rapide, et l'équilibrage comme la réduction ne touchent que l'entraînement, jamais le test, pour que nos résultats restent honnêtes.

Slide 6 : Prétraitement

Le prétraitement suit la séquence classique : minuscules, retrait de la ponctuation, des URL et des chiffres, puis tokenisation et suppression des mots vides. Deux finesses à retenir. On conserve les négations, car not good et good ont des sens opposés. Et la lemmatisation regroupe les formes d'un mot, crashing et crash deviennent le même mot, ce qui réduit le vocabulaire. Je passe la parole à Vénus pour la vectorisation.

Partie 2 : Vénus BAKIKO (slides 7 à 12)

Slide 7 : Vectorisation

Merci Yann. Les modèles ne comprennent que des nombres, il faut donc transformer le texte. On compare quatre représentations demandées par le sujet. Bag-of-Words compte les mots. TF-IDF fait pareil mais valorise les mots rares et discriminants. Word2Vec représente chaque mot par un vecteur dense, et on en a deux versions, une entraînée sur nos avis et une pré-entraînée sur Google News, qui est exactement le pre-trained Word2Vec du sujet. Détail utile : Naive Bayes multinomial exige des valeurs positives, donc pour les embeddings on passe à la version gaussienne.

Slide 8 : Les cinq modèles

Nous comparons cinq classifieurs, du plus simple au plus riche. Naive Bayes suppose les mots indépendants, c'est faux mais très efficace, et ce sera notre gagnant. L'arbre de décision est lisible mais surapprend, d'où l'élagage. La forêt aléatoire moyenne beaucoup d'arbres. Ada-Boost combine des souches, mais sur du texte creux il est faible. La régression logistique est une référence solide avec régularisation. Tous sont réglés par validation croisée en cinq blocs et recherche sur grille.

Slide 9 : Les métriques

Quatre mots à maîtriser. L'exactitude est la proportion globale de bonnes réponses, mais elle trompe quand une classe domine. La précision répond à : quand le modèle annonce une classe, a-t-il raison. Le rappel répond à : parmi les vrais cas, combien sont retrouvés. Le F1 combine les deux. Et le macro-F1 fait la moyenne des F1 des trois classes à égalité, donc rater la classe rare coûte cher. C'est pour cela qu'on règle sur le macro-F1.

Slide 10 : Résultats

Voici la comparaison de toutes les combinaisons. Le meilleur est TF-IDF avec Naive Bayes, à 0,559 de macro-F1. Le tableau donne le meilleur modèle pour chaque vectoriseur. Deux observations : les cinq premiers sont tous des méthodes par comptage, ce qui est logique sur des avis courts, et AdaBoost est dernier car ses souches ne voient qu'un mot à la fois. Les scores sont serrés autour de 0,5, car tous butent sur la même difficulté.

Slide 11 : Le piège de l'exactitude

Ce slide est le cœur de notre message. Notre meilleur modèle affiche 84 pour cent d'exactitude, ce qui paraît excellent. Mais la colonne neutre de la matrice de confusion est entièrement vide : le modèle ne prédit jamais la classe neutre. Les 53 vrais avis neutres sont tous classés en négatif ou positif. Le macro-F1 chute à 0,56 et révèle ce problème. La leçon : sur des données déséquilibrées, l'exactitude ment, il faut regarder le macro-F1 et le rappel par classe.

Slide 12 : Le déséquilibre

On attaque le déséquilibre. Sans traitement, le rappel de la classe neutre est exactement zéro : la minorité est ignorée. SMOTE génère des exemples neutres synthétiques et fait remonter ce rappel de zéro à 0,19. Le sous-échantillonnage va plus loin, à 0,47, mais en jetant des données. Le rééquilibrage échange donc de l'exactitude contre une vraie reconnaissance de la classe rare. Je laisse Faïçal pour les réglages et la conclusion.

Partie 3 : Faïçal DIELO (slides 13 à 18)

Slide 13 : Réduction de dimension

Merci Vénus. La réduction de dimension. Notre matrice TF-IDF a environ 4 600 colonnes. On utilise TruncatedSVD, l'équivalent de la PCA adapté aux données creuses. Le résultat est net : avec seulement 300 composantes, soit 6,5 pour cent des colonnes, on conserve quasiment toute la performance. C'est un excellent compromis vitesse mémoire, et c'est même indispensable avant un modèle dense comme le gradient boosting.

Slide 14 : Élagage de l'arbre

L'élagage de l'arbre de décision. Un arbre laissé libre construit 1 857 nœuds et mémorise les données : 0,98 en entraînement mais 0,76 en test, donc il surapprend. En élaguant, on réduit l'arbre à 69 nœuds et la performance de test monte à 0,79, tout en réduisant l'écart entre entraînement et test. Si on élague trop, vers 29 nœuds, l'arbre sous-apprend. C'est l'illustration concrète du compromis biais variance.

Slide 15 : Arrêt précoce

L'arrêt précoce pour le gradient boosting, un modèle qui ajoute des arbres un par un. On autorise jusqu'à 500 arbres, mais on surveille une part de validation et on arrête dès que la performance ne progresse plus. Ici l'arrêt survient à 88 arbres sur 500, soit environ six fois

moins de calcul, sans perte de qualité, et une protection contre le surapprentissage.

Slide 16 : Conclusion

Pour conclure. Nous avons construit une chaîne complète et reproductible sur de vrais avis Facebook, comparé quatre représentations du texte et cinq modèles, tous réglés par validation croisée. Le meilleur est TF-IDF avec Naive Bayes à 0,559 de macro-F1. La leçon principale est méthodologique : sur un jeu déséquilibré, l'exactitude trompe, et c'est le macro-F1 qui dit la vérité. SMOTE est ce qui permet à la classe minoritaire d'exister.

Slide 17 : Limites et perspectives

Soyons honnêtes sur les limites. Nos étiquettes viennent des étoiles, c'est un signal approximatif. La classe neutre est minuscule et ambiguë. Et le texte est court, bruité et parfois dans une autre langue. Côté perspectives, on peut activer BERT grâce au script que nous fournissons, essayer la pondération des classes et des seuils ajustés, et collecter de vraies issues GitHub ou JIRA.

Slide 18 : Remerciements

Merci de votre attention. Nous sommes maintenant prêts à répondre à vos questions. Pour les questions sur les métriques, pensez au macro-F1 et au rappel par classe. Pour celles sur le déséquilibre, pensez à SMOTE.

Bonne présentation à tous les trois.